

Эконометрика. Лекции и семинары

Баулин Евгений

14 сентября 2026 г.

Содержание

1 Вводная часть. 7 сентября 2026	2
2 Лекция и семинар. 7 сентября 2026	2
2.1 Зачем нужна эконометрика, когда есть продвинутое машинное обучение	2
2.2 Типы данных в эконометрике	2
2.3 Глоссарий	2
2.4 Пример эконометрической задачи	3
2.5 Модель	3
2.6 Задача эконометрики	3
2.7 Метод наименьших квадратов (МНК)	3
2.8 Частные случаи МНК	4
2.8.1 Регрессия на константу	4
2.8.2 Парная регрессия	4
2.9 Терминология и обозначения	4
2.10 Случай множественной регрессии	4
2.10.1 Минимизация суммы квадратов остатков	5
2.10.2 Оценка метода наименьших квадратов	5
2.11 Суммы квадратов	5
2.12 Если в регрессию включён свободный член	6
2.13 Коэффициент детерминации — простой показатель качества	6
2.13.1 Коэффициент детерминации в общем случае	6
2.14 Разбор с семинара	7
2.14.1 Что нужно помнить из теории вероятностей и статистики	7
2.14.2 Вывод МНК-оценки: регрессия на константу	7
2.14.3 Вывод МНК-оценок: парная регрессия	7
2.14.4 Свойства остатков МНК	8
2.14.5 Разложение общей суммы квадратов	9
2.14.6 Коэффициент детерминации в парной регрессии	9
2.14.7 Числовой пример	9
2.14.8 Как это считается на Python	10
2.14.9 Подводные камни	11
2.14.10 Задачи для самостоятельного решения	11

1 Вводная часть. 7 сентября 2026

Лектора зовут Анна Жимерикина

Telegram: [@ann_zhi](#)

Email: aj.zhimerikina@physics.msu.ru

О всех изменениях о парах будут сообщать в ТГК: [@ftiad_econ](#)

Правила посещения:

Отметок о посещении нет, поэтому посещение свободное (можно приходить, а можно и не приходить)

Тесты на семинарах как доп к оценке, то есть не писав их всё ещё можно получить 10. Тесты дадут максимум 1 – 1.5

Ровно в 9 pm заканчивается

Программировать будем только на Python

$$\text{Итоговая оценка} = 0.3 * ДЗ_1 + 0.4 * ДЗ_2 + 0.3 * КР$$

Можно просто написать в ЛС лектору, чтобы получить 4 за курс и не ходить на пары

Материалы: [Google Drive](#)

Ноутбук — опционально, можно не приносить, будут показывать экран

2 Лекция и семинар. 7 сентября 2026

2.1 Зачем нужна эконометрика, когда есть продвинутое машинное обучение

- Когда данных очень мало, а результат нужно получить сейчас
- Когда нужно полностью интерпретировать модель
- Всякие экономические модели

2.2 Типы данных в эконометрике

- Временные ряды (time-series data)
- Пространственные данные (cross-sectional data)
- Панельные данные (panel data)

Примеры смотреть в файле Лекция 1.pdf

2.3 Глоссарий

Всё, что y — target, целевая переменная, зависимая переменная, объясняемая переменная

Остальное — регрессоры, объясняющие переменные, features, признаки

По каждой переменной n наблюдений $y_1, y_2, \dots, y_n$

2.4 Пример эконометрической задачи

Как скорость машины влияет на длину тормозного пути? На каком расстоянии от пешеходного перехода установить знак?

Данные: Ezekiel, M. (1930) Methods of Correlation Analysis. Wiley (классический датасет `cars`: скорость в милях в час и длина тормозного пути в футах)

График смотреть в файле Лекция 1.pdf

2.5 Модель

Пусть мы знаем, что в реальности данные связаны следующим образом:

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$$

- Наблюдаемые нами переменные (наш датасет): y, x
- Неизвестные параметры: β_1, β_2 . Они существуют, но наблюдать мы их не можем
- Случайная составляющая, ошибка: ε

Ошибка возникает из-за несовершенства реальности:

- Ошибки измерений
- Неопределённость человеческого поведения
- Неучёт влияния бесчисленного множества случайных событий

Чтобы строить модели нужно включить здравый смысл и понять, что ошибка в измерениях — это нормально. Не нужно добавлять всё, что угодно (цену курицы, цвет машины и т. п.)

$\beta_1 + \beta_2 x_i$ — детерминированная часть

ε_i — стохастическая часть

2.6 Задача эконометрики

План действий:

1. Придумать адекватную модель (так как реальное устройство мира нам неизвестно, мы можем лишь делать предположение)
2. Получить оценки неизвестных параметров: $\hat{\beta}_1, \hat{\beta}_2$
3. Прогнозировать, заменив неизвестные параметры на оценки: $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i$

2.7 Метод наименьших квадратов (МНК)

Нужен способ получить оценки неизвестных параметров модели исходя из реальных данных

Ошибка прогноза: $\hat{\varepsilon}_i = y_i - \hat{y}_i$

Сумма квадратов ошибок прогноза:

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Суть МНК: В качестве оценок взять такие $\hat{\beta}_1, \hat{\beta}_2$, при которых сумма квадратов ошибок прогноза Q минимальна

2.8 Частные случаи МНК

2.8.1 Регрессия на константу

В модели $y_i = \beta + \varepsilon_i$: $\hat{\beta} = \bar{y}$

Интерпретация: В модели без объясняющих переменных наилучший прогноз — это среднее значение зависимой переменной

2.8.2 Парная регрессия

Модель с константой и одной независимой переменной

В модели $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$

$$\hat{\beta}_2 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{sCov(x, y)}{sVar(x)}$$
$$\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$$

Замечательное свойство: Точка $(\bar{x}, \bar{y})$ лежит на линии регрессии $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x$

2.9 Терминология и обозначения

- y_i — таргет, зависимая, объясняемая переменная
- x_i — feature, регрессор, независимая, объясняющая переменная
- ε - ошибка (несовершенство мира), случайная составляющая
- $\hat{y}_i$ — прогноз, прогнозное значение
- $\hat{e}_i = y_i - \hat{y}_i$ — остаток, ошибка прогноза (не путайте с ε)
- $RSS = \sum_{i=1}^n \hat{e}_i^2$ — сумма квадратов остатков

2.10 Случай множественной регрессии

Регрессоров может быть несколько, поэтому модель удобно записывать в матричном виде

Вектор зависимой переменной, вектор прогнозных значений и вектор случайных ошибок:

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \hat{y} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

Матрица регрессоров (первый столбец — константа), вектор коэффициентов и вектор их оценок:

$$X = \begin{pmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}, \quad \hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix}$$

Спецификация модели:

$$y = X\beta + \varepsilon$$

2.10.1 Минимизация суммы квадратов остатков

Вектор остатков: $e = y - \hat{y} = y - X\hat{\beta}$

Сумма квадратов остатков: $RSS = \sum \hat{e}_i^2 = e'e \rightarrow \min$

Выразим $e'e$ через X и $\hat{\beta}$:

$$\begin{aligned} e'e &= (y - X\hat{\beta})' (y - X\hat{\beta}) = \\ &= y'y - y'X\hat{\beta} - \hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta} = \\ &= y'y - 2\hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta} \end{aligned}$$

Слагаемые $y'X\hat{\beta}$ и $\hat{\beta}'X'y$ — это числа (матрицы размера 1×1), причём одно транспонировано к другому, поэтому они равны и складываются в $2\hat{\beta}'X'y$

2.10.2 Оценка метода наименьших квадратов

Необходимые условия минимума RSS получаются дифференцированием по вектору $\hat{\beta}$:

$$\frac{\partial RSS}{\partial \hat{\beta}} = -2X'y + 2X'X\hat{\beta} = 0$$

Решая уравнение, получаем оценку метода наименьших квадратов:

$$\hat{\beta}_{OLS} = (X'X)^{-1} X'y$$

Предположение: матрица $X'X$ обратима (столбцы X линейно независимы)

Если это не так (полная мультиколлинеарность), то оценка МНК не единственна

2.11 Суммы квадратов

- Сумма квадратов остатков, RSS (residual sum of squares):

$$RSS = \sum \hat{e}_i^2$$

- Общая сумма квадратов, TSS (total sum of squares) — вся дисперсия:

$$TSS = \sum (y_i - \bar{y})^2$$

- Объяснённая сумма квадратов, ESS (explained sum of squares):

$$ESS = \sum (\hat{y}_i - \bar{y})^2$$

Интерпретация ESS : ESS измеряет, насколько хорошо модель объяснила вариацию y по сравнению с простым средним $\bar{y}$. Чем больше доля ESS в TSS , тем лучше модель описывает данные

2.12 Если в регрессию включён свободный член

Если в регрессию включён свободный член, $y_i = \beta_1 + \dots$, и оценки МНК единственны, то:

- $\sum \hat{e}_i = 0$
- $\sum y_i = \sum \hat{y}_i$
- $\bar{y} = \bar{\hat{y}}$
- $TSS = RSS + ESS$

$$\underbrace{\sum (y_i - \bar{y})^2}_{TSS} = \underbrace{\sum (y_i - \hat{y}_i)^2}_{RSS} + \underbrace{\sum (\hat{y}_i - \bar{y})^2}_{ESS}$$

2.13 Коэффициент детерминации — простой показатель качества

Коэффициентом детерминации, или долей объяснённой дисперсии, называется

$$R^2 = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

В силу определения R^2 принимает значения между 0 и 1: $0 \leq R^2 \leq 1$

- $R^2 = 0$ означает, что регрессия ничего не даёт, то есть x_i не улучшает качество предсказания y_i по сравнению с тривиальным предсказанием $\hat{y}_i = \bar{y}$
- $R^2 = 1$ означает точную подгонку: все точки наблюдений лежат на регрессионной прямой (все $\hat{e}_i = 0$)

Важное замечание: $0 \leq R^2 \leq 1$ выполняется только при прогнозировании in sample. При прогнозе out-of-sample R^2 может принимать значения из $(-\infty; 1]$, то есть прогнозировать хуже выборочного среднего $\bar{y}$

Теорема: если в регрессию включён свободный член, $y_i = \beta_1 + \dots$, и оценки МНК единственны, то R^2 равен квадрату выборочной корреляции между y и $\hat{y}$:

$$R^2 = (sCorr(y, \hat{y}))^2 = \left(\frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{\sum (y_i - \bar{y})^2} \sqrt{\sum (\hat{y}_i - \bar{y})^2}} \right)^2$$

2.13.1 Коэффициент детерминации в общем случае

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{MSE}{Var(y)}$$

- MSE может быть бесконечно большой величиной
- В библиотеке `sklearn` эта формула реализована в `sklearn.metrics.r2_score`

Из документации `sklearn`: функция не симметрична, и, в отличие от большинства других метрик, R^2 может быть отрицательным (он не обязан быть квадратом какой-либо величины R)

2.14 Разбор с семинара

На семинаре выводим формулы, которые на лекции были даны в готовом виде, и считаем всё то же самое руками и на Python

2.14.1 Что нужно помнить из теории вероятностей и статистики

Все формулы МНК записываются через выборочные моменты. Для выборок $x_1, \dots, x_n$ и $y_1, \dots, y_n$:

- Выборочное среднее: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- Выборочная дисперсия: $sVar(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$
- Выборочная ковариация: $sCov(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$
- Выборочная корреляция: $sCorr(x, y) = \frac{sCov(x, y)}{\sqrt{sVar(x)}\sqrt{sVar(y)}}$

Замечание: в формуле для $\hat{\beta}_2$ множители $\frac{1}{n}$ в числителе и знаменателе сокращаются, поэтому не важно, делить суммы на n или на $n - 1$ — оценка коэффициента от этого не изменится

Тождества, которые постоянно используются в выкладках:

- $\sum (x_i - \bar{x}) = 0$
- $\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum (x_i - \bar{x})y_i = \sum x_i y_i - n\bar{x}\bar{y}$
- $\sum (x_i - \bar{x})^2 = \sum x_i(x_i - \bar{x}) = \sum x_i^2 - n\bar{x}^2$

2.14.2 Вывод МНК-оценки: регрессия на константу

Модель $y_i = \beta + \varepsilon_i$, прогноз $\hat{y}_i = \hat{\beta}$. Минимизируем

$$Q(\hat{\beta}) = \sum_{i=1}^n (y_i - \hat{\beta})^2$$

Необходимое условие минимума:

$$\frac{dQ}{d\hat{\beta}} = -2 \sum_{i=1}^n (y_i - \hat{\beta}) = 0 \implies \sum_{i=1}^n y_i = n\hat{\beta} \implies \hat{\beta} = \bar{y}$$

Это действительно минимум: $\frac{d^2Q}{d\hat{\beta}^2} = 2n > 0$, то есть Q строго выпукла

2.14.3 Вывод МНК-оценок: парная регрессия

Модель $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$, прогноз $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i$. Минимизируем

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{i=1}^n (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i)^2$$

Приравниваем к нулю частные производные и получаем систему нормальных уравнений:

$$\begin{aligned}\frac{\partial Q}{\partial \hat{\beta}_1} &= -2 \sum (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i) = 0 \\ \frac{\partial Q}{\partial \hat{\beta}_2} &= -2 \sum x_i (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i) = 0\end{aligned}$$

Из первого уравнения:

$$\sum y_i = n\hat{\beta}_1 + \hat{\beta}_2 \sum x_i \implies \bar{y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{x} \implies \hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$$

Это ровно то самое замечательное свойство с лекции: точка $(\bar{x}, \bar{y})$ лежит на линии регрессии. Подставляем $\hat{\beta}_1$ во второе уравнение:

$$\begin{aligned}\sum x_i (y_i - \bar{y} + \hat{\beta}_2 \bar{x} - \hat{\beta}_2 x_i) &= 0 \\ \sum x_i (y_i - \bar{y}) &= \hat{\beta}_2 \sum x_i (x_i - \bar{x})\end{aligned}$$

Пользуясь тождествами выше, получаем формулу с лекции:

$$\hat{\beta}_2 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{sCov(x, y)}{sVar(x)}$$

Интерпретация: $\hat{\beta}_2$ показывает, на сколько единиц в среднем изменится y , если x вырастет на одну единицу. Знак $\hat{\beta}_2$ совпадает со знаком выборочной ковариации x и y

2.14.4 Свойства остатков МНК

Нормальные уравнения — это в точности условия ортогональности остатков регрессорам. Отсюда сразу следуют свойства, которые на лекции были даны списком:

- $\sum \hat{e}_i = 0$ — первое нормальное уравнение (верно, только если в модели есть константа)
- $\sum x_i \hat{e}_i = 0$ — второе нормальное уравнение
- $\bar{y} = \bar{\hat{y}}$ — следствие первого: $\sum \hat{y}_i = \sum (y_i - \hat{e}_i) = \sum y_i$

В матричном виде все нормальные уравнения записываются одной строкой:

$$X'e = 0 \iff X'(y - X\hat{\beta}) = 0 \iff X'X\hat{\beta} = X'y$$

Если матрица $X'X$ обратима, отсюда получается формула с лекции: $\hat{\beta}_{OLS} = (X'X)^{-1} X'y$

Геометрический смысл: $\hat{y} = X(X'X)^{-1} X'y$ — проекция вектора y на линейную оболочку столбцов X , а вектор остатков e ортогонален этой оболочке. МНК ищет ближайшую к y точку среди тех, которые модель вообще способна описать

2.14.5 Разложение общей суммы квадратов

Запишем отклонение от среднего как сумму двух слагаемых:

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}) = \hat{e}_i + (\hat{y}_i - \bar{y})$$

Возводим в квадрат и суммируем:

$$\sum (y_i - \bar{y})^2 = \sum \hat{e}_i^2 + \sum (\hat{y}_i - \bar{y})^2 + 2 \sum \hat{e}_i (\hat{y}_i - \bar{y})$$

Осталось показать, что перекрёстное слагаемое равно нулю:

$$\sum \hat{e}_i (\hat{y}_i - \bar{y}) = \sum \hat{e}_i (\hat{\beta}_1 + \hat{\beta}_2 x_i - \bar{y}) = (\hat{\beta}_1 - \bar{y}) \underbrace{\sum \hat{e}_i}_{=0} + \hat{\beta}_2 \underbrace{\sum x_i \hat{e}_i}_{=0} = 0$$

Получаем $TSS = RSS + ESS$. Обратите внимание: доказательство целиком опирается на нормальные уравнения, поэтому без константы в модели разложение, вообще говоря, ломается

2.14.6 Коэффициент детерминации в парной регрессии

Задача: показать, что в парной регрессии $R^2 = (sCorr(x, y))^2$

Решение. Так как $\hat{y}_i - \bar{y} = \hat{\beta}_2 (x_i - \bar{x})$, то

$$ESS = \hat{\beta}_2^2 \sum (x_i - \bar{x})^2 = \frac{(\sum (x_i - \bar{x}) (y_i - \bar{y}))^2}{\sum (x_i - \bar{x})^2}$$

Делим на $TSS = \sum (y_i - \bar{y})^2$:

$$R^2 = \frac{ESS}{TSS} = \frac{(\sum (x_i - \bar{x}) (y_i - \bar{y}))^2}{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2} = (sCorr(x, y))^2$$

То есть в парной регрессии R^2 не различает, что на что регрессируем: он одинаков для регрессии y на x и для регрессии x на y

2.14.7 Числовой пример

x_i	1	2	3	4	5
y_i	2	4	5	4	5

Считаем средние: $\bar{x} = 3$, $\bar{y} = 4$

$$\begin{aligned} \sum (x_i - \bar{x}) (y_i - \bar{y}) &= (-2)(-2) + (-1) \cdot 0 + 0 \cdot 1 + 1 \cdot 0 + 2 \cdot 1 = 6 \\ \sum (x_i - \bar{x})^2 &= 4 + 1 + 0 + 1 + 4 = 10 \end{aligned}$$

Отсюда

$$\hat{\beta}_2 = \frac{6}{10} = 0.6, \quad \hat{\beta}_1 = 4 - 0.6 \cdot 3 = 2.2, \quad \hat{y}_i = 2.2 + 0.6x_i$$

Прогнозы и остатки:

$\hat{y}_i$	2.8	3.4	4.0	4.6	5.2
$\hat{e}_i$	-0.8	0.6	1.0	-0.6	-0.2

Проверка свойств остатков: $\sum \hat{e}_i = 0$ и $\sum x_i \hat{e}_i = 0$

Суммы квадратов: $RSS = 2.4$, $ESS = \hat{\beta}_2^2 \cdot 10 = 3.6$, $TSS = 6$. Действительно, $TSS = RSS + ESS$, а

$$R^2 = 1 - \frac{2.4}{6} = 0.6$$

2.14.8 Как это считается на Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

df = pd.read_csv('cars.csv')    # speed (мили в час), dist (футы)
x = df['speed'].to_numpy()
y = df['dist'].to_numpy()

# 1. МНК руками по формулам парной регрессии
beta2 = np.sum((x - x.mean()) * (y - y.mean())) / np.sum((x - x.mean()) ** 2)
beta1 = y.mean() - beta2 * x.mean()

# 2. МНК в матричном виде
X = sm.add_constant(x)          # добавляем столбец из единиц
beta = np.linalg.solve(X.T @ X, X.T @ y)  # надёжнее, чем np.linalg.inv

# 3. МНК через statsmodels
model = sm.OLS(y, X).fit()
print(model.params)              # те же beta1, beta2
print(model.summary())

# 4. Суммы квадратов и коэффициент детерминации
y_hat = X @ beta
e = y - y_hat
rss = np.sum(e ** 2)
tss = np.sum((y - y.mean()) ** 2)
ess = np.sum((y_hat - y.mean()) ** 2)

print(rss + ess, tss)            # совпадают
print(1 - rss / tss, model.rsquared)  # тоже совпадают
print(e.sum(), (x * e).sum())     # оба нуля с точностью до машинной
```

Полезно помнить:

- Константа не добавляется сама: без `sm.add_constant` модель оценивается без свободного члена, и ломаются и R^2 , и свойства остатков
- Считать $(X'X)^{-1}$ через `np.linalg.inv` не нужно: `np.linalg.solve` и `np.linalg.lstsq` точнее и устойчивее численно

- В `sklearn` за константу в `LinearRegression` отвечает параметр `fit_intercept` (по умолчанию `True`), а R^2 считает метод `score`

2.14.9 Подводные камни

- R^2 не убывает при добавлении любого нового регрессора, даже бессмысленного, поэтому сравнивать по нему модели с разным числом регрессоров нельзя
- Регрессия y на x и регрессия x на y дают разные прямые. Их коэффициенты связаны соотношением $\hat{\beta}_{y|x} \cdot \hat{\beta}_{x|y} = R^2$
- Высокий R^2 ничего не говорит о причинно-следственной связи
- Единицы измерения: если заменить x на cx , то $\hat{\beta}_2$ поделится на c , а прогнозы, остатки и R^2 не изменятся

2.14.10 Задачи для самостоятельного решения

1. Показать, что в модели без константы $y_i = \beta x_i + \varepsilon_i$ МНК-оценка равна $\hat{\beta} = \frac{\sum x_i y_i}{\sum x_i^2}$
2. Показать, что в модели без константы, вообще говоря, $\sum \hat{e}_i \neq 0$, разложение $TSS = RSS + ESS$ не выполняется, а R^2 , посчитанный по формуле $1 - RSS/TSS$, может оказаться отрицательным
3. Все y_i увеличили на константу c . Как изменятся $\hat{\beta}_1$, $\hat{\beta}_2$, RSS и R^2 ?
4. Показать, что $\hat{\beta}_2 = sCorr(x, y) \cdot \sqrt{\frac{sVar(y)}{sVar(x)}}$
5. Взять датасет `cars` из лекции, построить регрессию длины тормозного пути на скорость и проинтерпретировать оба коэффициента. Имеет ли содержательный смысл $\hat{\beta}_1$?