

Эконометрика. Лекции и семинары

Баулин Евгений

7 сентября 2026 г.

Содержание

1	Вводная часть. 7 сентября 2026	2
2	Лекция и семинар. 7 сентября 2026	2
2.1	Зачем нужна эконометрика, когда есть продвинутое машинное обучение	2
2.2	Типы данных в эконометрике	2
2.3	Глоссарий	2
2.4	Пример эконометрической задачи	3
2.5	Модель	3
2.6	Задача эконометрики	3
2.7	Метод наименьших квадратов (МНК)	3
2.8	Частные случаи МНК	4
2.8.1	Регрессия на константу	4
2.8.2	Парная регрессия	4
2.9	Терминология и обозначения	4
2.10	Случай множественной регрессии	4
2.10.1	Минимизация суммы квадратов остатков	5
2.10.2	Оценка метода наименьших квадратов	5
2.11	Суммы квадратов	5
2.12	Если в регрессию включён свободный член	6
2.13	Коэффициент детерминации — простой показатель качества	6
2.13.1	Коэффициент детерминации в общем случае	6
2.14	Литература	7

1 Вводная часть. 7 сентября 2026

Лектора зовут Анна Жимерикина

Telegram: [@ann_zhi](#)

Email: aj.zhimerikina@physics.msu.ru

О всех изменениях о парах будут сообщать в ТГК: [@ftiad_econ](#)

Правила посещения:

Отметок о посещении нет, поэтому посещение свободное (можно приходить, а можно и не приходить)

Тесты на семинарах как доп к оценке, то есть не писав их всё ещё можно получить 10. Тесты дадут максимум 1 – 1.5

Ровно в 9 pm заканчивается

Программировать будем только на Python

$$\text{Итоговая оценка} = 0.3 * ДЗ_1 + 0.4 * ДЗ_2 + 0.3 * КР$$

Можно просто написать в ЛС лектору, чтобы получить 4 за курс и не ходить на пары

Материалы: [Google Drive](#)

Ноутбук — опционально, можно не приносить, будут показывать экран

2 Лекция и семинар. 7 сентября 2026

2.1 Зачем нужна эконометрика, когда есть продвинутое машинное обучение

- Когда данных очень мало, а результат нужно получить сейчас
- Когда нужно полностью интерпретировать модель
- Всякие экономические модели

2.2 Типы данных в эконометрике

- Временные ряды (time-series data)
- Пространственные данные (cross-sectional data)
- Панельные данные (panel data)

Примеры смотреть в файле Лекция 1.pdf

2.3 Глоссарий

Всё, что y — target, целевая переменная, зависимая переменная, объясняемая переменная

Остальное — регрессоры, объясняющие переменные, features, признаки

По каждой переменной n наблюдений $y_1, y_2, \dots, y_n$

2.4 Пример эконометрической задачи

Как скорость машины влияет на длину тормозного пути? На каком расстоянии от пешеходного перехода установить знак?

Данные: Ezekiel, M. (1930) *Methods of Correlation Analysis*. Wiley (классический датасет **cars**: скорость в милях в час и длина тормозного пути в футах)

График смотреть в файле Лекция 1.pdf

2.5 Модель

Пусть мы знаем, что в реальности данные связаны следующим образом:

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$$

- Наблюдаемые нами переменные (наш датасет): y, x
- Неизвестные параметры: β_1, β_2 . Они существуют, но наблюдать мы их не можем
- Случайная составляющая, ошибка: ε

Ошибка возникает из-за несовершенства реальности:

- Ошибки измерений
- Неопределённость человеческого поведения
- Неучёт влияния бесчисленного множества случайных событий

Чтобы строить модели нужно включить здравый смысл и понять, что ошибка в измерениях — это нормально. Не нужно добавлять всё, что угодно (цену курицы, цвет машины и ТП)

$\beta_1 + \beta_2 x_i$ — детерминированная часть

ε_i — стохастическая часть

2.6 Задача эконометрики

План действий:

1. Придумать адекватную модель (так как реальное устройство мира нам неизвестно, но мы можем лишь делать предложение)
2. Получить оценки неизвестных параметров: $\hat{\beta}_1, \hat{\beta}_2$
3. Прогнозировать, заменив неизвестные параметры на оценки: $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i$

2.7 Метод наименьших квадратов (МНК)

Нужен способ получить оценки неизвестных параметров модели исходя из реальных данных

Ошибка прогноза: $\hat{\varepsilon}_i = y_i - \hat{y}_i$

Сумма квадратов ошибок прогноза:

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Суть МНК: В качестве оценок взять такие $\hat{\beta}_1, \hat{\beta}_2$, при которых сумма квадратов ошибок прогноза Q минимальна

2.8 Частные случаи МНК

2.8.1 Регрессия на константу

В модели $y_i = \beta + \varepsilon_i$: $\hat{\beta} = \bar{y}$

Интерпретация: В модели без объясняющих переменных наилучший прогноз — это среднее значение зависимой переменной

2.8.2 Парная регрессия

Модель с константой и одной независимой переменной

В модели $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$

$$\hat{\beta}_2 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{sCov(x, y)}{sVar(x)}$$
$$\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$$

Замечательное свойство: Точка $(\bar{x}, \bar{y})$ лежит на линии регрессии $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x$

2.9 Терминология и обозначения

- y_i — таргет, зависимая, объясняемая переменная
- x_i — feature, регрессор, независимая, объясняющая переменная
- ε - ошибка (несовершенство мира), случайная составляющая
- $\hat{y}_i$ — прогноз, прогнозное значение
- $\hat{e}_i = y_i - \hat{y}_i$ — остаток, ошибка прогноза (не путайте с ε)
- $RSS = \sum_{i=1}^n \hat{e}_i^2$ — сумма квадратов остатков

2.10 Случай множественной регрессии

Регрессоров может быть несколько, поэтому модель удобно записывать в матричном виде

Вектор зависимой переменной, вектор прогнозных значений и вектор случайных ошибок:

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \hat{y} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

Матрица регрессоров (первый столбец — константа), вектор коэффициентов и вектор их оценок:

$$X = \begin{pmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}, \quad \hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix}$$

Спецификация модели:

$$y = X\beta + \varepsilon$$

2.10.1 Минимизация суммы квадратов остатков

Вектор остатков: $e = y - \hat{y} = y - X\hat{\beta}$

Сумма квадратов остатков: $RSS = \sum \hat{e}_i^2 = e'e \rightarrow \min$

Выразим $e'e$ через X и $\hat{\beta}$:

$$\begin{aligned} e'e &= (y - X\hat{\beta})' (y - X\hat{\beta}) = \\ &= y'y - y'X\hat{\beta} - \hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta} = \\ &= y'y - 2\hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta} \end{aligned}$$

Слагаемые $y'X\hat{\beta}$ и $\hat{\beta}'X'y$ — это числа (матрицы размера 1×1), причём одно транспонировано к другому, поэтому они равны и складываются в $2\hat{\beta}'X'y$

2.10.2 Оценка метода наименьших квадратов

Необходимые условия минимума RSS получаются дифференцированием по вектору $\hat{\beta}$:

$$\frac{\partial RSS}{\partial \hat{\beta}} = -2X'y + 2X'X\hat{\beta} = 0$$

Решая уравнение, получаем оценку метода наименьших квадратов:

$$\hat{\beta}_{OLS} = (X'X)^{-1} X'y$$

Предположение: матрица $X'X$ обратима (столбцы X линейно независимы)

Если это не так (полная мультиколлинеарность), то оценка МНК не единственна

2.11 Суммы квадратов

- Сумма квадратов остатков, RSS (residual sum of squares):

$$RSS = \sum \hat{e}_i^2$$

- Общая сумма квадратов, TSS (total sum of squares) — вся дисперсия:

$$TSS = \sum (y_i - \bar{y})^2$$

- Объяснённая сумма квадратов, ESS (explained sum of squares):

$$ESS = \sum (\hat{y}_i - \bar{y})^2$$

Интерпретация ESS : ESS измеряет, насколько хорошо модель объяснила вариацию y по сравнению с простым средним $\bar{y}$. Чем больше доля ESS в TSS , тем лучше модель описывает данные

2.12 Если в регрессию включён свободный член

Если в регрессию включён свободный член, $y_i = \beta_1 + \dots$, и оценки МНК единственны, то:

- $\sum \hat{e}_i = 0$
- $\sum y_i = \sum \hat{y}_i$
- $\bar{y} = \bar{\hat{y}}$
- $TSS = RSS + ESS$

$$\underbrace{\sum (y_i - \bar{y})^2}_{TSS} = \underbrace{\sum (y_i - \hat{y}_i)^2}_{RSS} + \underbrace{\sum (\hat{y}_i - \bar{y})^2}_{ESS}$$

2.13 Коэффициент детерминации — простой показатель качества

Коэффициентом детерминации, или долей объяснённой дисперсии, называется

$$R^2 = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

В силу определения R^2 принимает значения между 0 и 1: $0 \leq R^2 \leq 1$

- $R^2 = 0$ означает, что регрессия ничего не даёт, то есть x_i не улучшает качество предсказания y_i по сравнению с тривиальным предсказанием $\hat{y}_i = \bar{y}$
- $R^2 = 1$ означает точную подгонку: все точки наблюдений лежат на регрессионной прямой (все $\hat{e}_i = 0$)

Важное замечание: $0 \leq R^2 \leq 1$ выполняется только при прогнозировании in sample. При прогнозе out-of-sample R^2 может принимать значения из $(-\infty; 1]$, то есть прогнозировать хуже выборочного среднего $\bar{y}$

Теорема: если в регрессию включён свободный член, $y_i = \beta_1 + \dots$, и оценки МНК единственны, то R^2 равен квадрату выборочной корреляции между y и $\hat{y}$:

$$R^2 = (sCorr(y, \hat{y}))^2 = \left(\frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{\sum (y_i - \bar{y})^2} \sqrt{\sum (\hat{y}_i - \bar{y})^2}} \right)^2$$

2.13.1 Коэффициент детерминации в общем случае

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{MSE}{Var(y)}$$

- MSE может быть бесконечно большой величиной
- В библиотеке `sklearn` эта формула реализована в `sklearn.metrics.r2_score`

Из документации `sklearn`: функция не симметрична, и, в отличие от большинства других метрик, R^2 может быть отрицательным (он не обязан быть квадратом какой-либо величины R)

2.14 Литература

- Магнус Я.Р., Катышев П.К., Пересецкий А.А. Эконометрика. Начальный курс: Учеб. — 9-е изд., испр. — М.: Издательский дом «Дело» РАНХиГС, 2021. — 504 с. Главы: 1, 2.1, 2.2, 2.6
- Грин У.Г. Эконометрический анализ. Кн. 1 / У. Грин; пер. с англ.; под науч. ред. С.С. Синельникова, М.Ю. Турунцевой. — М.: Издательский дом «Дело» РАНХиГС, 2016. — 760 с. (Академический учебник). ISBN 978-5-7749-1157-8. Главы: 2.1, 2.2