



Эконометрика

Лекция 1

Метод наименьших квадратов

Зачем нужна эконометрика, когда есть продвинутое машинное обучение

- Когда мало данных (меньше 100–200 наблюдений)
- Когда нужна модель с возможностью полной интерпретации

- Временные ряды (time-series data)
- Пространственные данные (cross-sectional data)
- Панельные данные (panel data)

Временные ряды

Акции Сбербанк России (SBER)

КАПИТАЛИЗАЦИЯ
5 630 523.65 млн RUB
58 553.15 млн USD

EPS
12.55 RUB

P/E
18.36

ДИВ. ДОХОДНОСТЬ
ЗА 4 КВ.
9.58%

ОТРАСЛЬ
Банки

Данные рассчитаны по ценам с торговой площадки: Московская Биржа

Московская Биржа

ЗА ПОСЛЕДНИЙ МЕСЯЦ

изменения динамика цены

+1.88% 253.10 269.11
min max

ЗА ПОСЛЕДНИЙ ГОД

изменения динамика цены

+87.00% 96.50 273.35
min max

260.83 RUB (+0.32%) LAST на 15.09.2023
17.09.2023 - выходной, биржа закрыта

ГРАФИК



ДАТА	BID ASK	OPEN	MIN MAX	LAST	LEGAL CLOSE	AVG	ОБОРОТ	КОЛ-ВО СДЕЛОК
15.09.2023	260.86 260.87	259.65	258.56 262.74	260.83	260.89	260.76	9 278 013 469.00	86 323.00
14.09.2023	259.99 260.00	258.90	255.02 261.38	260.00	260.38	257.94	11 926 939 185.60	111 224.00
13.09.2023	258.14 258.18	262.40	257.59 262.77	258.18	259.47	260.22	7 819 079 988.10	84 439.00
12.09.2023	262.38 262.40	257.70	257.09 262.40	262.40	260.75	259.78	11 734 500 325.70	109 806.00
11.09.2023	256.19 256.25	257.00	255.16 258.37	256.25	256.27	256.90	11 118 813 229.20	109 499.00
08.09.2023	255.66 255.67	258.08	253.10 259.33	255.68	256.45	256.30	12 703 139 529.30	119 240.00
07.09.2023	258.79 258.80	263.69	256.10 264.97	258.79	257.90	259.79	17 586 948 788.70	165 037.00
06.09.2023	263.50 263.51	264.33	262.31 264.68	263.50	263.50	263.39	7 464 966 620.50	83 975.00
05.09.2023	264.74 264.75	266.74	261.09 267.98	264.75	265.51	265.55	10 571 300 705.40	102 654.00
04.09.2023	267.35 267.39	266.50	266.00 269.11	267.39	267.17	267.48	12 877 036 020.60	110 101.00

Источник: <https://investfunds.ru/stocks/Sberbank/>

Пространственные данные (cross-sectional data)

```
df = pd.read_csv('/kaggle/input/housing-prices-dataset/Housing.csv')
df
```

	price	area	bedrooms	bathrooms	stories	mainroad	guestroom	basement	hotwaterheating	airconditioning	parking	prefarea	furnishingstatus
0	13300000	7420	4	2	3	yes	no	no	no	yes	2	yes	furnished
1	12250000	8960	4	4	4	yes	no	no	no	yes	3	no	furnished
2	12250000	9960	3	2	2	yes	no	yes	no	no	2	yes	semi-furnished
3	12215000	7500	4	2	2	yes	no	yes	no	yes	3	yes	furnished
4	11410000	7420	4	1	2	yes	yes	yes	no	yes	2	no	furnished
...	...	...	...	...	...	...	...	...	...	...	...	...	...
540	1820000	3000	2	1	1	yes	no	yes	no	no	2	no	unfurnished
541	1767150	2400	3	1	1	no	no	no	no	no	0	no	semi-furnished
542	1750000	3620	2	1	1	yes	no	no	no	no	0	no	unfurnished
543	1750000	2910	3	1	1	no	no	no	no	no	0	no	furnished
544	1750000	3850	3	1	2	yes	no	no	no	no	0	no	unfurnished

Источник: <https://www.kaggle.com/code/abhijeetsinghmeena/eda-house-price-prediction>

Панельные данные

Test subject number	Year	Monthly rent	Annual income
1	2015	\$2,000	\$65,000
1	2016	\$2,100	\$65,000
1	2017	\$2,200	\$65,000
2	2015	\$3,500	\$80,000
2	2016	\$3,500	\$82,000
2	2017	\$3,400	\$77,000
3	2015	\$1,800	\$65,000
3	2016	\$2,000	\$70,000
3	2017	\$2,300	\$70,000


Источник: <https://www.indeed.com/career-advice/career-development/panel-data>

- Зависимая, объясняемая переменная, таргет, целевая: y
- Регрессоры, объясняющие переменные, features, признаки: $x, z, \dots$
- По каждой переменной n наблюдений: $y_1, y_2, \dots, y_n$

Пример эконометрической задачи

Как скорость машины влияет на длину тормозного пути?

На каком расстоянии от пешеходного перехода установить знак?



Ezekiel, M. (1930) Methods of Correlation Analysis. Wiley.

Пусть мы знаем, что в реальности данные связаны следующим образом:

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$$

- Наблюдаемые нами переменные (наш датасет): y, x
- Неизвестные параметры: β_1, β_2
Они существуют, но наблюдать мы их не можем
- Случайная составляющая, ошибка: ε

Ошибка возникает из-за несовершенства реальности:

- Ошибки измерений
- Неопределенность человеческого поведения
- Неучет влияния бесчисленного множества случайных событий

$\beta_1 + \beta_2 x_i$ - детерминированная часть

ε_i - стохастическая часть

План действий:

- Придумать адекватную модель (так как реальное устройство мира нам неизвестно, мы можем лишь делать предположение)
- Получить оценки неизвестных параметров: $\hat{\beta}_1, \hat{\beta}_2$
- Прогнозировать, заменив неизвестные параметры на оценки:

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i$$

Метод наименьших квадратов

Нужен способ получить оценки неизвестных параметров модели исходя из реальных данных.

Ошибка прогноза: $\hat{e}_i = y_i - \hat{y}_i$

Сумма квадратов ошибок прогноза:

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Суть МНК

В качестве оценок взять такие $\hat{\beta}_1, \hat{\beta}_2$, при которых сумма квадратов ошибок прогноза Q минимальна.

Частные случаи МНК. Регрессия на константу

В модели $y_i = \beta + \varepsilon_i$

$$\hat{\beta} = \bar{y}$$

Интерпретация

В модели без объясняющих переменных наилучший прогноз — это среднее значение зависимой переменной

Частные случаи МНК. Парная регрессия

Модель с константой и одной независимой переменной

В модели $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$

$$\hat{\beta}_2 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{sCov(x, y)}{sVar(x)}$$

$$\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$$

Замечательное свойство

Точка $(\bar{x}, \bar{y})$ лежит на линии регрессии $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x$

- y_i — таргет, зависимая, объясняемая переменная
- x_i — feature, регрессор, независимая, объясняющая переменная
- ε_i — ошибка (несовершенство мира), случайная составляющая
- $\hat{y}_i$ — прогноз, прогнозное значение
- $\hat{e}_i = y_i - \hat{y}_i$ — остаток, ошибка прогноза (не путайте с ε !)
- $RSS = \sum_{i=1}^n \hat{e}_i^2$ — сумма квадратов остатков

Случай множественной регрессии

- Вектор зависимой переменной

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

- Матрица регрессоров (с константой)

$$X = \begin{pmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}$$

- Вектор случайных ошибок

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- Вектор прогнозных значений

$$\hat{y} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{pmatrix}$$

- Вектор коэффициентов

$$\beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}$$

- Оценки коэффициентов

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix}$$

$$y = X\beta + \varepsilon \quad \text{— спецификация модели}$$

Случай множественной регрессии

Минимизация суммы квадратов остатков

- Вектор остатков: $e = y - \hat{y} = y - X\hat{\beta}$
- Сумма квадратов остатков: $RSS = \sum e_t^2 = e'e \rightarrow \min$

Выразим $e'e$ через X и $\hat{\beta}$:

$$\begin{aligned}e'e &= (y - X\hat{\beta})'(y - X\hat{\beta}) \\&= y'y - y'X\hat{\beta} - \hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta} \\&= y'y - 2X'y\hat{\beta} + \hat{\beta}'X'X\hat{\beta}\end{aligned}$$

* Магнус Я.Р., Катышев П.К., Пересецкий А.А. Эконометрика. Начальный курс: Учеб. — 9-е изд., испр. — М.: Издательский дом «Дело» РАНХиГС, 2021. — 504 с., стр. 64

Случай множественной регрессии

Оценка метода наименьших квадратов

Необходимые условия минимума RSS получаются дифференцированием по вектору $\hat{\beta}$:

$$\frac{\partial RSS}{\partial \hat{\beta}} = -2X'y + 2X'X\hat{\beta} = 0$$

Решая уравнение, получаем оценку метода наименьших квадратов:

$$\hat{\beta}_{OLS} = (X'X)^{-1}X'y$$

Предположение

Матрица $X'X$ обратима (столбцы X линейно независимы)

* Магнус Я.Р., Катышев П.К., Пересецкий А.А. Эконометрика. Начальный курс: Учеб. — 9-е изд., испр. — М.: Издательский дом «Дело» РАНХиГС, 2021. — 504 с., стр. 64

Суммы квадратов

- Сумма квадратов остатков, **RSS** (residual sum of squares)

$$RSS = \sum \hat{e}_i^2$$

- Общая сумма квадратов, **TSS** (total sum of squares) - вся дисперсия

$$TSS = \sum (y_i - \bar{y})^2$$

- Объясненная сумма квадратов, **ESS** (explained sum of squares)

$$ESS = \sum (\hat{y}_i - \bar{y})^2$$

Интерпретация ESS

ESS измеряет, насколько хорошо модель объяснила вариацию y по сравнению с простым средним $\bar{y}$. Чем больше доля ESS в TSS, тем лучше модель описывает данные.

Если в регрессию включён свободный член β_1

Если в регрессию включён свободный член, $y_i = \beta_1 + \dots$, и оценки МНК единственны, то:

- $\sum \hat{\varepsilon}_i = 0$
- $\sum y_i = \sum \hat{y}_i$
- $\bar{y} = \bar{\hat{y}}$
- $TSS = RSS + ESS$

$$\sum_{TSS} (y_t - \bar{y})^2 = \sum_{RSS} (y_t - \hat{y}_t)^2 + \sum_{ESS} (\hat{y}_t - \bar{y})^2$$

Коэффициент детерминации — простой показатель качества

Определение

Коэффициентом детерминации, или долей объясненной дисперсии, называется

$$R^2 = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

В силу определения R^2 принимает значения между 0 и 1, $0 \leq R^2 \leq 1$.

- $R^2 = 0$, означает, что регрессия ничего не дает, т.е. x_t не улучшает качество предсказания y_t по сравнению с тривиальным предсказанием $\hat{y}_t = \bar{y}$.
- $R^2 = 1$ означает точную подгонку: все точки наблюдений лежат на регрессионной прямой (все $e_t = 0$).

* Магнус Я.Р., Катышев П.К., Пересецкий А.А. Эконометрика. Начальный курс: Учеб. — 9-е изд., испр. — М.: Издательский дом «Дело» РАНХиГС, 2021. — 504 с., стр. 49

Коэффициент детерминации — простой показатель качества

Важное замечание

$0 \leq R^2 \leq 1$ лежит в таких пределах только при прогнозировании in sample. При прогнозе out-of-sample он может принимать значения $(-\infty; 1]$, то есть прогнозировать хуже выборочного среднего $\bar{y}$.

Коэффициент детерминации — простой показатель качества

Теорема

Если в регрессию включён свободный член, $y_i = \beta_1 + \dots$, и оценки МНК единственны, то R^2 равен квадрату выборочной корреляции между y и $\hat{y}$:

$$R^2 = (sCorr(y, \hat{y}))^2 = \left(\frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{\sum (y_i - \bar{y})^2} \sqrt{\sum (\hat{y}_i - \bar{y})^2}} \right)^2$$

Коэффициент детерминации — в общем случае

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{MSE}{Var(y)}$$

- MSE может быть бесконечно большой величиной
- В библиотеке `sklearn.metrics.r2score` реализована эта формула

Notes

This is not a symmetric function.

Unlike most other scores, R^2 score may be negative (it need not actually be the square of a quantity R).

- Магнус Я.Р., Катышев П.К., Пересецкий А.А.
Эконометрика. Начальный курс: Учеб. — 9-е изд., испр. — М.: Издательский дом «Дело» РАНХиГС, 2021. — 504 с.
Главы: 1, 2.1, 2.2, 2.6
- Грин, У.Г.
Эконометрический анализ. Кн. 1 / У. Грин ; пер. с англ. ; под науч. ред. С.С. Синельникова, М.Ю. Турунцевой. — Москва : Издательский дом «Дело» РАНХиГС, 2016. — 760 с. (Академический учебник). - ISBN 978-5-7749-1157-8.
Главы 2.1, 2.2